

MODI (ISP) - projekt II, zadanie 28

Temat: identyfikacja modeli statycznych i dynamicznych metodą najmniejszych kwadratów.

Autor: Mikołaj Wróbel 337021

Sprawozdanie jest wykonane przy pomocy jupiterowego notebooka zatem jest w pełni edytowanym sprazodaniem. Komórki kodu uruchamiają istniejące pliki źródłowe Pythona, przeliczają metryki oraz wstawiają wygenerowane wykresy. Po zmianie list stopni/rzędów modeli wystarczy uruchomić notebook ponownie od góry.

Założenia i metoda

Modele wyznaczono metodą najmniejszych kwadratów bez użycia specjalizowanych bibliotek identyfikacyjnych. Dla macierzy regresorów Φ i wektora wyjść y parametry modelu spełniają równanie normalne:

$$\Phi^T \Phi \theta = \Phi^T y. \quad (1)$$

W implementacji układ normalny jest rozwiązywany solverem eliminacji Gaussa z częściowym wyborem elementu głównego. Dokładność oceniono metrykami:

$$MSE = \frac{1}{N} \sum_{k=1}^N (y(k) - \hat{y}(k))^2, \quad RMSE = \sqrt{MSE}. \quad (2)$$

```
In [83]: from pathlib import Path
import html
import importlib.util
import os
import subprocess
import sys

import numpy as np
import matplotlib.pyplot as plt
from IPython.display import HTML, Image, Markdown, display

# Jeśli notebook zostanie otwarty z innego katalogu, znajdź katalog projektu po fol
def find_project_root(start: Path) -> Path:
    for candidate in [start, *start.parents]:
        if (candidate / "danestat28").exists() and (candidate / "danedynucz28").exi
            return candidate
    raise FileNotFoundError("Nie znaleziono katalogu projektu z folderami danych.")

ROOT = find_project_root(Path.cwd().resolve())
STATIC_CODE = ROOT / "identyfikacja_modeli_statycznych" / "kod"
DYNAMIC_CODE = ROOT / "identyfikacja_modeli_dynamicznych" / "kod"

GENERATE_NOTEBOOK_FIGURES = True
```

Uruchomienie kodu źródłowego

Ta komórka wywołuje oba skrypty główne: część statyczną i dynamiczną. Skrypty generują wszystkie wykresy używane dalej w sprawozdaniu. Jeżeli chcesz tylko przejrzeć raport bez ponownego liczenia, ustaw `RUN_MAIN_SCRIPTS = False`.

```
In [85]: RUN_MAIN_SCRIPTS = True

def run_project_script(script: Path):
    env = os.environ.copy()
    env["MPLBACKEND"] = "Agg"
    env["PYTHONIOENCODING"] = "utf-8"
    result = subprocess.run(
        [sys.executable, str(script)],
        cwd=str(ROOT),
        capture_output=True,
        text=True,
        encoding="utf-8",
        errors="replace",
        env=env,
    )
    result.check_returncode()
    return result

if RUN_MAIN_SCRIPTS:
    run_project_script(STATIC_CODE / "main.py")
    run_project_script(DYNAMIC_CODE / "main.py")
```

1. Identyfikacja modeli statycznych

Dane statyczne podzielono na zbiór uczący i weryfikujący w proporcji 60% do 40%. W pierwszej kolumnie danych znajduje się wejście u , a w drugiej wyjście y .

```
In [86]: static_import = load_module("modi_static_import", STATIC_CODE / "import_danych.py")
static_models = load_module("modi_static_models", STATIC_CODE / "modele.py")
static_plotting = load_module("modi_static_plotting", STATIC_CODE / "rysowanie.py")

STATIC_SPLIT = 0.6
STATIC_POLY_DEGREES = list(range(1, 21))


dane_stat = static_import.Import_Static_Data(split=STATIC_SPLIT)
plotter_stat = static_plotting.PlotData(dane_stat.out_dir)

if GENERATE_NOTEBOOK_FIGURES:
    plotter_stat.plot_all_data(dane_stat.u, dane_stat.y)
    plotter_stat.plot_static_characteristic(dane_stat.u, dane_stat.y)
    plotter_stat.plot_training_data(dane_stat.u_ucz, dane_stat.y_ucz)
    plotter_stat.plot_training_characteristic(dane_stat.u_ucz, dane_stat.y_ucz)
    plotter_stat.plot_verification_data(dane_stat.u_wer, dane_stat.y_wer, dane_stat)
    plotter_stat.plot_verification_characteristic(dane_stat.u_wer, dane_stat.y_wer)
    plt.close("all")
```


1a. Dane statyczne

Poniżej pokazano przebiegi sygnałów oraz charakterystyki statyczne dla wszystkich danych, zbioru uczącego i zbioru weryfikującego.



Dane statyczne - wszystkie próbki (N = 200)





Charakterystyka statyczna $y = f(u)$ - wszystkie dane



Zbiór uczący - 60 % próbek ($N_{ucz} = 120$)



Zbiór weryfikujący - 40 % próbek ($N_{wer} = 80$)



1b. Statyczny model liniowy

Rozważany model ma postać:

$$y(u) = a_0 + a_1 u. \quad (3)$$


Wektor parametrów $[a_0, a_1]^T$ wyznaczono metodą MNK na zbiorze uczącym, a jakość oceniono osobno dla danych uczących i weryfikujących.

Model liniowy: $y(u) = 0.977620 + 1.436710u$

Metryki modelu liniowego


Model	MSE ucz.	RMSE ucz.	MSE wer.	RMSE wer.
liniowy N=1	0,897856	0,947552	0,844686	0,919068

Charakterystyka statyczna - model liniowy





Model liniowy - zbiór weryfikujący

Wyjście modelu na tle danych weryfikujących (MSE=0,8447, RMSE=0,9191)



Błąd predykcji





Komentarz: model liniowy stanowi punkt odniesienia. Jeżeli rozrzut punktów na wykresie y względem $\hat{y}$ jest systematycznie zakrzywiony, oznacza to, że sama zależność liniowa nie opisuje wystarczająco nieliniowej charakterystyki statycznej.

1c. Statyczne modele wielomianowe

Testowany model wielomianowy ma postać:


$$y(u) = a_0 + \sum_{i=1}^N a_i u^i. \quad (4)$$

Stopnie wielomianu można edytować w zmiennej `STATIC_POLY_DEGREES` powyżej. Najlepszy model wybieramy na podstawie najmniejszego błędu na zbiorze weryfikującym, zwracając uwagę na ryzyko przeuczenia przy wysokich stopniach.


Metryki statycznych modeli wielomianowych

N	L. par.	MSE ucz.	RMSE ucz.	MSE wer.	RMSE wer.
1	2	0,897856	0,947552	0,844686	0,919068
2	3	0,191942	0,438112	0,207590	0,455620
3	4	0,002217	0,047085	0,002472	0,049715
4	5	0,001903	0,043619	0,002290	0,047859
5	6	0,001899	0,043574	0,002318	0,048142
6	7	0,001896	0,043547	0,002273	0,047674
7	8	0,001869	0,043236	0,002271	0,047651
8	9	0,001868	0,043218	0,002282	0,047766
9	10	0,001865	0,043186	0,002270	0,047648
10	11	0,001848	0,042987	0,002167	0,046549
11	12	0,001832	0,042806	0,002221	0,047126
12	13	0,001832	0,042806	0,002229	0,047207
13	14	0,001792	0,042333	0,002172	0,046600
14	15	0,001740	0,041711	0,002494	0,049935
15	16	0,001736	0,041666	0,002385	0,048840
16	17	0,001718	0,041454	0,002319	0,048156
17	18	0,001717	0,041440	0,002339	0,048368
18	19	0,001703	0,041263	0,002503	0,050025
19	20	0,001700	0,041226	0,002414	0,049137
20	21	0,001695	0,041169	0,002762	0,052551



Najniższy błąd weryfikacji uzyskano dla modelu wielomianowego **N=10** (MSE=0.002167, RMSE=0.046549).




Wykresy najlepszego modelu statycznego: N=10



Model wielomianowy N=10 - zbiór weryfikujący





Wybór modelu statycznego: za najlepszy przyjęto model o najmniejszym MSE na zbiorze weryfikującym. Porównanie błędów uczących i weryfikujących pozwala sprawdzić, czy wzrost stopnia wielomianu poprawia uogólnianie, czy tylko dopasowanie do danych uczących.

2. Identyfikacja modeli dynamicznych

Dane dynamiczne są dostarczone w dwóch plikach: zbiór uczący i zbiór weryfikujący. Modele dynamiczne porównano w trybie bez rekurencji oraz z rekurencją. Do wyboru końcowego istotny jest przede wszystkim tryb rekurencyjny, bo odpowiada pracy modelu jako symulatora.

```
In [92]: dynamic_import = load_module("modi_dynamic_import", DYNAMIC_CODE / "import_danych.p
dynamic_models = load_module("modi_dynamic_models", DYNAMIC_CODE / "modele_dynamicz
dynamic_plotting = load_module("modi_dynamic_plotting", DYNAMIC_CODE / "rysowanie.p

ARX_ORDERS = [1, 2, 3]

# Etap 1: szerokie przeszukiwanie, odpowiadające ustawieniu pretrained = False.
pretrained = False
if pretrained == False:
    NARX_PRETRAIN_ORDERS = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 20, 30, 40, 50]
```

```

NARX_PRETRAIN_DEGREES = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 20, 30, 40, 50]

# Etap 2: przeszukiwanie zawężone, odpowiadające ustawieniu pretrained = True.
pretrained = True
if pretrained == True:
    NARX_ORDERS = [13, 14, 15, 16, 17, 18, 19, 20]
    NARX_DEGREES = [3, 4, 5, 6]


dane_dyn = dynamic_import.ImportDynamicData(base_dir=str(ROOT))
plotter_dyn = dynamic_plotting.PlotDynamic(dane_dyn.out_dir)

if GENERATE_NOTEBOOK_FIGURES:
    plotter_dyn.plot_training_data(dane_dyn.u_ucz, dane_dyn.y_ucz)
    plotter_dyn.plot_verification_data(dane_dyn.u_wer, dane_dyn.y_wer)
    plt.close("all")


```

2a. Dane dynamiczne

Poniżej znajdują się przebiegi sygnałów wejściowych i wyjściowych dla zbioru uczącego oraz weryfikującego.



Dane dynamiczne - zbiór weryfikujący (N = 2000)



2b. Dynamiczne modele liniowe ARX

Dla rzędów $n_A = n_B \in \{1, 2, 3\}$ wyznaczono modele:

$$y(k) = \sum_{i=1}^{n_B} b_i u(k-i) + \sum_{i=1}^{n_A} a_i y(k-i). \quad (5)$$

Tryb bez rekurencji używa zmierzonych opóźnionych wartości y , natomiast tryb rekurencyjny używa wcześniejszych wartości wyjścia modelu $\hat{y}$.

Metryki modeli ARX


n	L. par.	MSE ucz. NR	RMSE ucz. NR	MSE wer. NR	RMSE wer. NR	MSE ucz. R	RMSE ucz. R	MSE wer. R	RMSE wer. R
1	2	0,001974	0,044427	0,002631	0,051291	2,821949	1,679866	1,202792	1,096719
2	4	0,001923	0,043857	0,002384	0,048823	2,625758	1,620419	1,213854	1,101751
3	6	0,001594	0,039920	0,001798	0,042403	2,098656	1,448674	1,219444	1,104284

Najlepszy model liniowy w trybie rekurencyjnym: **ARX rzędu 1** (MSE=1.202792, RMSE=1.096719).


Wykresy najlepszego modelu ARX w trybie rekurencyjnym: $n=1$

ARX rzędu 1 - zbiór weryfikujący (z rekurencją)


Wyjście modelu vs dane weryfikujące (MSE=1,2028, RMSE=1,0967)



Błąd predykcji



Relacja danych weryf. vs model ARX(1) - z rekurencją



Komentarz: tryb bez rekurencji daje mniejsze błędy, ponieważ korzysta z rzeczywistych opóźnionych wyjść i model w takiej formie działa. Natomiast gdy spróbuje się go użyć praktycznie czyli w trybie rekurencyjnym błędy zaczynają się akumulować. Tryb rekurencyjny ujawnia rzeczywistą przydatność modelu do symulacji procesu i jest ona wątpliwa.

2c. Dynamiczne modele nieliniowe NARX

Rozważono wielomianowe modele dynamiczne bez wyrazów mieszanych:

$$y(k) = \sum_{i=1}^{n_B} \sum_{p=1}^d w_{i,p} u(k-i)^p + \sum_{i=1}^{n_A} \sum_{p=1}^d v_{i,p} y(k-i)^p. \quad (6)$$

W tym notebooku zakres przeszukiwania określają listy `NARX_ORDERS` i `NARX_DEGREES`. Liczba parametrów wynosi $2n_A d$ przy $n_A = n_B$.

Przeszukiwanie przeprowadzono **dwuetapowo**:

1. **Etap 1 (pretrained = False)** – szerokie przeszukiwanie siatki $n_A \in \{1-10, 20, 30, 40, 50\}$, $d \in \{1-10, 20, 30, 40, 50\}$ w celu ustalenia obiecującego obszaru.
2. **Etap 2 (pretrained = True)** – zawężone przeszukiwanie wokół minimum znalezione w etapie 1.

Etap 1 – wstępne przeszukiwanie (pretrained = False)

```
In [96]: RUN_NARX_PRETRAIN = False # True = przelicz na nowo (wolne, ~196 modeli); False =
```

Szerokie przeszukiwanie przeprowadzono jednorazowo na siatce `NARX_PRETRAIN_ORDERS = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 20, 30, 40, 50]` × `NARX_PRETRAIN_DEGREES = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 20, 30, 40, 50]`.

Najlepszy wynik (etap 1): NARX($n_A=n_B=20$, $d=4$) → MSE wer. R = 0.000573.

Na tej podstawie zawężono zakres do `NARX_ORDERS = [13, 14, 15, 16, 17, 18, 19, 20]`, `NARX_DEGREES = [3, 4, 5, 6]`.

Etap 2 – zawężone przeszukiwanie (pretrained = True)



Na podstawie wyników etapu 1 zawężono siatkę do $n_A \in \{13-20\}$, $d \in \{3, 4, 5, 6\}$ i powtórzono przeszukiwanie.

Metryki modeli NARX

nA=nB	d	L. par.	MSE ucz. NR	RMSE ucz. NR	MSE wer. NR	RMSE wer. NR	MSE ucz. R	RMSE ucz. R	MSE wer. R	RMSE wer. R
13	3	78	0,000582	0,024120	0,000620	0,024905	0,000735	0,027106	0,000725	0,026924
13	4	104	0,000559	0,023643	0,000615	0,024802	0,000556	0,023570	0,000589	0,024268
13	5	130	0,000552	0,023496	0,000623	0,024957	0,000555	0,023555	0,000598	0,024449
13	6	156	0,000544	0,023324	0,000631	0,025118	0,000555	0,023550	0,000614	0,024783
14	3	84	0,000576	0,023996	0,000615	0,024804	0,000733	0,027069	0,000713	0,026693
14	4	112	0,000548	0,023412	0,000611	0,024728	0,000545	0,023353	0,000581	0,024107
14	5	140	0,000541	0,023266	0,000622	0,024933	0,000544	0,023327	0,000594	0,024362
14	6	168	0,000532	0,023060	0,000632	0,025137	0,000540	0,023246	0,000610	0,024699
15	3	90	0,000569	0,023862	0,000610	0,024689	0,000732	0,027055	0,000708	0,026611
15	4	120	0,000536	0,023142	0,000605	0,024598	0,000535	0,023124	0,000580	0,024078
15	5	150	0,000529	0,022994	0,000619	0,024883	0,000532	0,023057	0,000592	0,024327
15	6	180	0,000518	0,022769	0,000631	0,025113	0,000528	0,022970	0,000605	0,024603
16	3	96	0,000566	0,023793	0,000610	0,024695	0,000735	0,027106	0,000699	0,026431
16	4	128	0,000529	0,023001	0,000603	0,024555	0,000529	0,023001	0,000570	0,023884
16	5	160	0,000521	0,022834	0,000615	0,024807	0,000524	0,022896	0,000578	0,024045
16	6	192	0,000511	0,022598	0,000629	0,025082	0,000520	0,022796	0,000592	0,024335
17	3	102	0,000563	0,023729	0,000609	0,024677	0,000731	0,027042	0,000697	0,026405
17	4	136	0,000522	0,022845	0,000600	0,024489	0,000526	0,022935	0,000572	0,023907
17	5	170	0,000513	0,022656	0,000612	0,024738	0,000520	0,022802	0,000579	0,024071
17	6	204	0,000502	0,022401	0,000628	0,025051	0,000515	0,022683	0,000594	0,024370
18	3	108	0,000560	0,023667	0,000612	0,024735	0,000728	0,026986	0,000695	0,026359
18	4	144	0,000517	0,022747	0,000599	0,024478	0,000524	0,022890	0,000571	0,023903
18	5	180	0,000509	0,022550	0,000613	0,024749	0,000518	0,022755	0,000580	0,024078
18	6	216	0,000497	0,022290	0,000628	0,025055	0,000512	0,022626	0,000591	0,024317
19	3	114	0,000559	0,023649	0,000610	0,024707	0,000728	0,026982	0,000693	0,026325
19	4	152	0,000513	0,022655	0,000598	0,024449	0,000522	0,022846	0,000572	0,023916
19	5	190	0,000504	0,022454	0,000611	0,024714	0,000516	0,022705	0,000580	0,024081
19	6	228	0,000491	0,022164	0,000626	0,025018	0,000509	0,022555	0,000591	0,024304
20	3	120	0,000557	0,023604	0,000615	0,024794	0,000731	0,027035	0,000695	0,026371
20	4	160	0,000509	0,022563	0,000598	0,024457	0,000521	0,022815	0,000573	0,023931
20	5	200	0,000499	0,022345	0,000615	0,024794	0,000514	0,022663	0,000583	0,024152
20	6	240	0,000486	0,022044	0,000630	0,025090	0,000507	0,022510	0,000595	0,024396

Najlepszy model nieliniowy w trybie rekurencyjnym: **NARX(nA=nB=16, d=4)** z 128 parametrami (MSE=0.000570, RMSE=0.023884).

Wykresy najlepszego modelu NARX w trybie rekurencyjnym: $n_A=n_B=16$, $d=4$




Wybór modelu nieliniowego: jako kryterium podstawowe przyjęto najmniejsze MSE weryfikacyjne w trybie rekurencyjnym. Jeżeli dwa modele mają bardzo zbliżone błędy, praktycznie korzystniejszy jest model o mniejszej liczbie parametrów, bo jest mniej podatny na przeuczenie i łatwiejszy do interpretacji.

2d. Charakterystyka statyczna z modelu NARX

Charakterystykę statyczną najlepszego modelu NARX wyznaczono metodą symulacyjną. Dla stałego wejścia u^* uruchomiono model rekurencyjnie przez wiele próbek, a ostatnią wartość $\hat{y}$ potraktowano jako stan ustalony.

Porównanie charakterystyki statycznej w 3 punktach

u^*	y statyczne	y NARX	$ \text{błąd} $
-0,846223	0,776698	0,847879	0,071180
-0,097748	-0,357367	-0,288268	0,069098
0,855879	2,819566	2,871001	0,051434



Wnioski końcowe

1. Model liniowy jest użytecznym punktem odniesienia, ale w części statycznej dokładniejsze wyniki daje model wielomianowy dobrany na podstawie błędu weryfikacyjnego.
2. W modelach dynamicznych ocena rekurencyjna jest surowsza od predykcji bez rekurencji, bo błędy modelu wpływają na kolejne próbki.
3. Najlepszy model NARX dobrany według MSE weryfikacyjnego w trybie rekurencyjnym najlepiej nadaje się do dalszej symulacji i do wyznaczenia charakterystyki statycznej metodą symulacyjną.

4. Zgodność charakterystyki statycznej NARX z danymi statycznymi należy oceniać nie tylko po trzech punktach kontrolnych, ale też po kształcie całej krzywej względem chmury danych.

3. Identyfikacja modelem neuronowym (Keras)

Statyczny model neuronowy z **jedną warstwą ukrytą**:

$$\hat{y}(u) = \sum_{j=1}^H v_j \cdot \tanh\left(\sum_{i=1}^1 w_{ji} u + b_j^{(1)}\right) + b^{(2)}, \quad (7)$$

gdzie H – liczba neuronów ukrytych. Wagi uczone metodą minimalizacji MSE algorytmem wstecznej propagacji błędu.

Rozważono trzy przypadki:

Przypadek	Neurony ukryte	Liczba parametrów
Zbyt mała	1	4
Umiarkowana	10	31
Zbyt duża	500	1 501

Dla każdego przypadku uczenie powtórzono przy zmianach:

- **algorytmu optymalizacji**: Adam, SGD, RMSprop (przy $\text{lr} = 0,01$ i stałym punkcie startowym),
- **współczynnika uczenia**: 0,001 / 0,01 / 0,1 (przy Adam i stałym punkcie startowym),
- **punktu startowego wag**: seed = 42 / 123 / 999 (przy Adam i $\text{lr} = 0,01$).


Backend Keras: PyTorch (TensorFlow nie wspiera Pythona 3.14).

```
In [102... RUN_NEURAL = False # True = przelicz od nowa (wolne, ~27 modeli); False = wczytaj
```


3a. Sieć zbyt mała (1 neuron ukryty)

Sieć z jednym neuronem ukrytym ma tylko **4 parametry**. Funkcja $\tanh$ daje krzywą sigmoidalną – model nie jest w stanie odwzorować złożonej charakterystyki statycznej.


Zmiana optymalizatora ($\text{lr}=0.01$, $\text{seed}=42$)




Zmiana współczynnika uczenia (Adam, seed=42)



Zmiana punktu startowego (Adam, lr=0.01)




Charakterystyka statyczna – najlepszy model




3b. Sieć umiarkowana (10 neuronów ukrytych)

Sieć z 10 neuronami ukrytymi ma **31 parametrów**. Powinna być wystarczająco elastyczna do aproksymacji statycznej charakterystyki, przy jednoczesnym braku wyraźnego przeuczenia.


Zmiana optymalizatora (lr=0.01, seed=42)




Zmiana współczynnika uczenia (Adam, seed=42)



Zmiana punktu startowego (Adam, lr=0.01)




Charakterystyka statyczna – najlepszy model




3c. Sieć zbyt duża (500 neuronów ukrytych)

Sieć z 500 neuronami ukrytymi ma **1 501 parametrów** – ponad 12-krotnie więcej niż danych uczących. Oczekuje się przeuczenia: MSE uczący będzie bardzo niski, ale MSE weryfikujący może wzrosnąć.


Zmiana optymalizatora (lr=0.01, seed=42)




Zmiana współczynnika uczenia (Adam, seed=42)



Zmiana punktu startowego (Adam, lr=0.01)



Charakterystyka statyczna – najlepszy model



3d. Zestawienie wyników

Porównanie MSE najlepszych modeli każdego rozmiaru




Tabela dostępna po uruchomieniu z `RUN_NEURAL = True`.

3e. Omówienie wyników

Sieć zbyt mała (1 neuron, 4 par.):

Jeden neuron z $\tanh$ może odwzorować jedynie monotoniczną krzywą sigmoidalną. Jeżeli charakterystyka statyczna jest bardziej złożona, sieć nie jest w stanie dobrze dopasować danych – MSE weryfikacyjny pozostaje wysoki dla wszystkich optymalizatorów, współczynników uczenia i punktów startowych. Wynik jest mało wrażliwy na wybór algorytmu i punktu startowego, bo obszar rozwiązań jest bardzo ubogi.

Sieć umiarkowana (10 neuronów, 31 par.):

Sieć ma wystarczającą pojemność do aproksymacji nielinearności. Kluczowe obserwacje:

- **Wpływ optymalizatora:** Adam i RMSprop zazwyczaj schodzą szybciej niż SGD; przy tym samym lr SGD wymaga więcej epok lub wyższego lr .
- **Wpływ lr :** Zbyt małe lr (0,001) prowadzi do wolnej zbieżności w 4000 epokach. Zbyt duże lr (0,1) może powodować oscylacje lub zatrzymanie w lokalnym minimum. Optymalny zakres to $\text{lr} \approx 0,01$.
- **Wpływ punktu startowego:** Przy umiarkowanej sieci dobry optymalizator i odpowiedni lr prowadzą do podobnych wyników niezależnie od startu (stabilna zbieżność), choć mogą wystąpić lokalne minima.

Sieć zbyt duża (500 neuronów, 1 501 par.):

Liczba parametrów przekracza 12-krotnie liczbę danych uczących. Sieć może **zapamiętać** dane zamiast nauczyć się ich wzorca:

- MSE uczący jest bardzo niski (bliski zera przy wystarczającej liczbie epok),
- MSE weryfikujący może być wyraźnie wyższy niż dla sieci umiarkowanej – to **przeuczenie** (*overfitting*).
- Różne punkty startowe prowadzą do bardziej rozproszonych wyników, bo przestrzeń wag jest ogromna.

Ogólne wnioski:

1. Dla tego zadania (statyczna identyfikacja) sieć z 10 neuronami jest rozsądnym wyborem.
2. Algorytm Adam z $\text{lr} \approx 0,01$ zapewnia najszybszą i najbardziej niezawodną zbieżność.
3. Modele neuronowe osiągają niższe MSE weryfikacyjne niż model liniowy, zbliżone do modelu wielomianowego wyższego stopnia, ale bez ryzyka "wibracji" na krańcach przedziału.
4. Porównując z NARX: statyczny model neuronowy aproksymuje tylko charakterystykę $y(u)$, natomiast NARX modeluje pełną dynamikę – cel jest inny.

4. Identyfikacja własnym modelem neuronowym z optymalizacją Bayesowską

Implementacja od zera na **NumPy** (bez Keras/PyTorch/TensorFlow). Niegdyś na 5. Laby z przedmiotu WSI wykonano model AI, zgdaujący liczby od 0 do 9 z skutecznością na poziomie 98%. Skoro wykonano już gotowy model postarano się go dostosować do 2. projektu z przedmiotu MODI. Oto wyniki:

Zmiana względem 5. LAB WSI	Opis
Wyjście	liniowe zamiast softmax
Funkcja straty	MSE zamiast entropii krzyżowej
Gradient wyjściowy	$2 \cdot (\hat{y} - y) / N$ (liniowe + MSE)
Kryterium Bayesa	minimalizacja val MSE (negujemy score dla GP)

Przestrzeń przeszukiwania

Parametr	Zakres
Warstwy ukryte	1 – 4
Neurony na warstwę	8 – 128
Współczynnik uczenia η	0,001 – 0,1
Liczba epok	100 – 500
Rozmiar mini-batcha	16 – 128

Procedura

1. Faza losowa (`n_random_starts` konfiguracji) – eksploracja.
2. Faza GP-UCB – model Gaussa wskazuje obiecujące regiony.
3. Najlepsza konfiguracja (najniższy val MSE) jest przekazywana do wizualizacji.

In [108...

```
import sys
from pathlib import Path
import importlib
import numpy as np
import plotly.io as pio
pio.renderers.default = 'notebook'
```

```

# — Ścieżki —————
OWN_CODE = ROOT / "identyfikacja_modelem_neuronowym" / "identyfikacja_wlasnym_modelem"
MODEL_SAVE_PATH = str(OWN_CODE / "best_model")

if str(OWN_CODE.parent) not in sys.path:
    sys.path.insert(0, str(OWN_CODE.parent))

# — Import modułów własnego modelu —————
from identyfikacja_wlasnym_modelem.model import Model as OwnModel
from identyfikacja_wlasnym_modelem.trening import TrenujModel
from identyfikacja_wlasnym_modelem.bayes_optymalizacja import BayesOptymalizator
from identyfikacja_wlasnym_modelem.wizualizacja import (
    pokaz_architektura_3d, pokaz_postep_trenowania
)

# — Dane statyczne —————
neural_import_own = load_module("modi_neural_import", NEURAL_CODE / "import_danych.")
dane_own = neural_import_own.ImportStaticData(split=0.6)

u_ucz, y_ucz = dane_own.u_ucz, dane_own.y_ucz
u_wer, y_wer = dane_own.u_wer, dane_own.y_wer

# — Min-max normalizacja —————
u_min, u_max = u_ucz.min(), u_ucz.max()
y_min, y_max = y_ucz.min(), y_ucz.max()

def norm_u(u):
    return (u - u_min) / (u_max - u_min + 1e-12)

def norm_y(y):
    return (y - y_min) / (y_max - y_min + 1e-12)

def denorm_y(y_n):
    return y_n * (y_max - y_min) + y_min

X_train_own = norm_u(u_ucz).reshape(-1, 1)
y_train_own = norm_y(y_ucz).reshape(-1, 1)
X_val_own = norm_u(u_wer).reshape(-1, 1)
y_val_own = norm_y(y_wer).reshape(-1, 1)

```

In [109..

```

# — Flaga sterowania —————
RUN_OWN = False # True = uruchom optymalizację Bayesowską (wolne); False = wczyta

```

In [110..

```

if RUN_OWN:
    # — Optymalizacja Bayesowska —————
    optimizer = BayesOptymalizator(
        X_train_own, y_train_own,
        X_val_own, y_val_own,
        layers_range = (1, 4),
        nodes_range = (8, 128),
        lr_range = (1e-3, 0.1),
        epochs_range = (100, 500),
        batch_size_range = (16, 128),
        n_random_starts = 4,
        n_iterations = 50,
    )
    own_config, own_val_mse, own_trainer = optimizer.optymalizuj()

    # Zachowaj geometrię modelu (do wizualizacji)
    own_hidden = [own_config[f'nodes_{i+1}']] for i in range(own_config['num_layer

```

```

own_sizes      = [1] + own_hidden + [1]
own_acts       = ['relu'] * own_config['num_layers'] + ['linear']
own_val_mse_denorm = own_val_mse * (y_max - y_min) ** 2
own_test_mse_denorm = own_trainer.model.mse(X_val_own, y_val_own) * (y_max - y_min)

# Zapis do pliku (opcjonalnie)
own_trainer.model.save(MODEL_SAVE_PATH)
np.savez(
    str(OWN_CODE / "training_history"),
    loss_history      = own_trainer.loss_history,
    val_mse_history   = own_trainer.val_mse_history,
    own_sizes         = own_sizes,
    own_acts          = own_acts,
)

else:
    # — Wczytanie zapisanego modelu —————
    own_trainer_model = OwnModel.load(MODEL_SAVE_PATH)
    hist_data         = np.load(str(OWN_CODE / "training_history.npz"), allow_pickle=True)

    # Odtwórz trenera (do wykresu krzywych)
    class _FakeTrainer:
        pass

    own_trainer = _FakeTrainer()
    own_trainer.model      = own_trainer_model
    own_trainer.loss_history = hist_data['loss_history'].tolist()
    own_trainer.val_mse_history = hist_data['val_mse_history'].tolist()

    own_sizes = hist_data['own_sizes'].tolist()
    own_acts  = hist_data['own_acts'].tolist()

    own_val_mse_denorm = own_trainer.model.mse(X_val_own, y_val_own) * (y_max - y_min)

    display(Markdown("_Aby przeliczyć ponownie, zmień `RUN_OWN = True`._"))


```

Aby przeliczyć ponownie, zmień `RUN_OWN = True`.

4a. Architektura sieci (3D)


In [111... pokaz_architektura_3d(own_sizes, own_acts)

Architektura sieci (3D)




4b. Krzywe uczenia

Postęp trenowania (skala log)



4c. Charakterystyka statyczna – porównanie z danymi



Val MSE (oryg. skala): 0,008161 | Val RMSE: 0,090338 | Architektura: 1 → 126 → 74 → 32 → 1